

Đề tài cuối kỳ — Triển khai hệ thống Multi-Agent trên Edge

1. Mục tiêu

Sinh viên thiết kế, triển khai và đánh giá một hệ thống đa tác tử (multi-agent) chạy phân tán trên nhiều thiết bị edge có tài nguyên hạn chế. Đề án nhằm rèn ba năng lực cốt lõi của Edge AI:

- Đưa mô hình/agent chạy được trong ngân sách tài nguyên chặt (tối ưu, lượng tử hóa, đo lường).
- Phối hợp nhiều agent phân tán qua giao thức nhẹ, có xử lý lỗi.
- Đánh giá định lượng đánh đổi giữa độ trễ, tài nguyên và chất lượng.

Điểm khác biệt với một đề án hệ phân tán thuần túy: phần đo lường tài nguyên và tối ưu cho edge là trọng tâm chấm điểm, không phải phần phụ.

2. Yêu cầu bắt buộc

Kiến trúc

- Tối thiểu 3 agent, mỗi agent chạy trên 1 thiết bị edge riêng biệt.
- Mỗi thiết bị edge là một máy ảo cấu hình 2 vCPU, 4GB RAM (CPU-only, không GPU). Hệ thống phải chạy được đúng trong ngân sách này — vượt cấu hình sẽ bị trừ điểm.
- Các agent phải có vai trò khác nhau (không phải 3 bản sao cùng một chức năng). Ví dụ: thu thập/cảm biến, suy luận/phân tích, ra quyết định/hành động.
- Phải có cơ chế giao tiếp giữa các agent qua mạng (không dùng bộ nhớ chung, không giả lập bằng gọi hàm nội bộ).

Suy luận cục bộ

- Ít nhất một agent phải chạy suy luận AI cục bộ trên thiết bị edge của nó (mô hình ngôn ngữ nhỏ đã lượng tử hóa, mô hình thị giác, hoặc mô hình học máy khác).

Phối hợp & độ bền

- Phải mô tả rõ mô hình điều phối: tập trung (có orchestrator) hay phi tập trung (các agent tự thương lượng).
- Phải xử lý được ít nhất một tình huống lỗi: ví dụ một agent ngắt kết nối, timeout, hoặc phản hồi sai định dạng. Hệ thống không được sập toàn bộ khi một node hỏng.

Đo lường

- Với mỗi agent, đo và báo cáo: RAM đỉnh, %CPU trung bình/đỉnh, độ trễ xử lý (p50 và p95), và throughput (ví dụ tokens/giây hoặc request/giây).
- Đo độ trễ đầu-cuối của một tác vụ hoàn chỉnh đi qua nhiều agent.
- Nếu dùng LLM cục bộ: ghi rõ tên mô hình, số tham số, mức lượng tử hóa, và kích thước file.

3. Gợi ý miền ứng dụng

Nhóm tự chọn ứng dụng, miễn thỏa yêu cầu ở Mục 2. Một số hướng đã cân nhắc tính khả thi với cấu hình 2 core/4GB:

- **Giám sát môi trường thông minh.** Agent cảm biến (đọc dữ liệu, tiền xử lý) → Agent phân tích/dự báo → Agent quyết định & cảnh báo.
- **Thị giác phân tán.** Nhiều agent camera chạy phát hiện đối tượng nhẹ (ví dụ YOLO-nano/tiny hoặc mô hình phân loại) → Agent tổng hợp → Agent ra quyết định/cảnh báo.
- **Trợ lý hỏi-đáp phân tán (RAG).** Agent truy hồi tài liệu → Agent suy luận (LLM nhỏ cục bộ) → Agent tổng hợp câu trả lời.

- **Bảo trì dự đoán.** Mỗi agent giám sát một "máy" (dữ liệu cảm biến giả lập), phát hiện bất thường cục bộ, báo về agent điều phối trung tâm.

Khuyến khích nhóm đề xuất miền riêng nếu bảo vệ được tính hợp lý.

4. Gợi ý công nghệ

Đây là gợi ý để tiết kiệm thời gian, không phải ràng buộc. Nhóm được tự chọn miễn giải trình được.

- **Chạy LLM cục bộ:** llama.cpp, Ollama, hoặc ONNX Runtime. Mô hình nhỏ đã lượng tử hóa phù hợp trên 4GB: Qwen2.5-0.5B/1.5B, Llama-3.2-1B, Gemma-2-2B (Q4). Mô hình ~3B Q4 là sát trần, cân nhắc kỹ.
- **Mô hình thị giác/ML nhẹ:** TFLite, ONNX Runtime, hoặc scikit-learn cho tác vụ không cần deep learning.
- **Giao tiếp giữa agent:** MQTT (Mosquitto) là lựa chọn kinh điển cho edge; hoặc REST (FastAPI/Flask), hoặc gRPC.
- **Điều phối:** có thể tự viết vòng điều phối, hoặc dùng LangGraph/CrewAI/AutoGen, nhưng lưu ý các framework này có chi phí bộ nhớ, cần kiểm tra chúng có vừa 4GB không trước khi cam kết.
- **Đo tài nguyên:** psutil, htop, hoặc docker stats nếu đóng gói bằng Docker.

5. Sản phẩm nộp

1. **Mã nguồn** có thể tái lập, kèm hướng dẫn triển khai từng agent lên đúng cấu hình VM (2 core/4GB). Ưu tiên đóng gói bằng Docker hoặc script cài đặt.
2. **Video demo** (5–10 phút) cho thấy hệ thống chạy thật trên các VM riêng biệt, gồm cả tình huống một agent bị lỗi.
3. **Báo cáo kỹ thuật** gồm: sơ đồ kiến trúc và vai trò từng agent; mô hình điều phối và giao thức giao tiếp đã chọn (kèm lý do); mô hình AI đã dùng và mức tối ưu/lượng tử hóa; bảng số liệu đo lường theo Mục 2 (RAM, CPU, độ trễ p50/p95, throughput); phân tích đánh đổi và giới hạn gặp phải do ràng buộc tài nguyên.

6. Điểm cộng (không bắt buộc)

- Áp dụng kỹ thuật tối ưu tiên bộ (pruning, distillation, so sánh nhiều mức lượng tử hóa và định lượng ảnh hưởng).
- So sánh có kiểm soát: edge-only với edge-cloud hybrid, kèm số liệu.
- Đo mức tiêu thụ năng lượng hoặc chi phí