

TRIỂN KHAI HỆ THỐNG MULTI-AGENT TRÊN EDGE

Ứng dụng giám sát môi trường thông minh với suy luận AI cục bộ

Học phần: Công nghệ điện đám mây và điện toán biên (CE2206)

[Họ và tên sinh viên] · [MSSV]

[Giảng viên hướng dẫn] · 08/2026

Nội dung trình bày

1. Bối cảnh & mục tiêu
2. Kiến trúc hệ thống
3. Ba agent & giao tiếp MQTT
4. Suy luận AI cục bộ (ONNX)
5. Xử lý lỗi & chế độ degraded
6. Hiện thực & triển khai
7. Kết quả thực nghiệm
8. Demo & dashboard
9. Kết luận & hướng phát triển

Bối cảnh

- **IoT / giám sát môi trường** cần xử lý liên tục gần nguồn dữ liệu
- Đưa toàn bộ suy luận lên **cloud** → độ trễ cao, phụ thuộc băng thông, rủi ro mất kết nối
- **Điện toán biên (Edge Computing)**: suy luận & điều phối trên nút gần cảm biến
- **Multi-agent**: tách vai trò thu thập → phân tích → quyết định trên các nút biên độc lập

Đề tài CE2206: triển khai ≥ 3 **agent**, giao tiếp **thật qua mạng**, ngân sách **2 vCPU / 4 GB / CPU-only**, đo lường **định lượng**

Mục tiêu đồ án

#	Mục tiêu
1	Thiết kế & triển khai 3 agent trên edge (2c/4GB, CPU-only)
2	Giao tiếp chỉ qua MQTT — không shared memory / gọi hàm nội bộ
3	Suy luận AI cục bộ trên Analysis Agent (ONNX Runtime)
4	Orchestrator tập trung nhẹ + fallback khi Analysis timeout
5	Đo lường E2E latency, RAM, throughput — số liệu tái lập được
6	Dashboard realtime phục vụ demo & quan sát vận hành

Miền ứng dụng

Giám sát môi trường thông minh

Thông số	Mô tả
Nhiệt độ	°C
Độ ẩm	%
PM2.5	µg/m³
CO ₂	ppm

- Dữ liệu cảm biến **giả lập có kiểm soát** (tỷ lệ anomaly cấu hình được)
- Pipeline: phát hiện bất thường → cảnh báo theo mức độ nghiêm trọng
- Phù hợp demo edge AI trên tài nguyên hạn chế

Kiến trúc tổng thể

Thành phần	Vị trí	Vai trò
Sensor Agent	Edge VM #1 (2 vCPU / 4 GB)	Thu thập dữ liệu cảm biến
Analysis Agent	Edge VM #2 (2 vCPU / 4 GB)	Suy luận AI cục bộ (ONNX)
Decision Agent	Edge VM #3 (2 vCPU / 4 GB)	Điều phối & phát cảnh báo
MQTT Broker	Mosquitto	Trung gian pub/sub

Luồng chính: Sensor → Analysis → Decision, tất cả qua MQTT

Mỗi agent = **container riêng** · Giao tiếp **100% MQTT** · Không GPU

Ba agent — vai trò

Agent	Vai trò	Trách nhiệm chính
Sensor	Thu thập	Giả lập cảm biến, chuẩn hóa, gán mã truy vết, gửi readings + heartbeat
Analysis	Suy luận AI	Nhận readings → ONNX Isolation Forest → trả kết quả + thời gian suy luận
Decision	Quyết định	Orchestrator tập trung nhẹ: tổng hợp, phát alert, xử lý timeout

Điều phối tập trung nhẹ: Decision là điểm kiểm soát thống nhất, không dùng framework nặng (CrewAI, LangGraph) để giữ RAM trong 4 GB

Luồng end-to-end (E2E)

Bước	Agent	Hành động
1	Sensor	Gửi bản tin đọc cảm biến kèm mã truy vết (trace ID)
2	Analysis	Suy luận ONNX → gửi kết quả (điểm bất thường, nhãn)
3	Decision	Tổng hợp → phát cảnh báo kèm độ trễ E2E

- **Mã truy vết (trace ID):** nối toàn pipeline, đo E2E từ lúc thu thập đến lúc cảnh báo
- **QoS 1** cho luồng nghiệp vụ — giảm mất tin, overhead vẫn thấp
- Payload **JSON** theo schema thống nhất giữa các agent

Giao tiếp MQTT

Topic	Người gửi	Người nhận	Nội dung
edge/sensor/readings	Sensor	Analysis, Decision	Dữ liệu cảm biến
edge/analysis/results	Analysis	Decision	Kết quả suy luận
edge/decision/alerts	Decision	Dashboard	Cảnh báo quyết định
edge/system/heartbeat	Mọi agent	Dashboard	Tín hiệu sống

Lý do chọn MQTT: pub/sub nhẹ, phù hợp IoT/edge; tách rời producer/consumer; overhead thấp hơn HTTP polling

Suy luận AI cục bộ

Thuộc tính	Giá trị
Thuật toán	Isolation Forest + StandardScaler
Định dạng model	ONNX (~1,16 MB)
Runtime	ONNX Runtime trên CPU
Đặc trưng đầu vào	Nhiệt độ, độ ẩm, PM2.5, CO ₂
Huấn luyện	2000 mẫu normal synthetic; contamination 5%

Chỉ **Analysis Agent** chạy AI — đúng mô hình edge: suy luận gần dữ liệu, không phụ thuộc cloud

Xử lý lỗi — Analysis timeout

Kịch bản bắt buộc: Analysis Agent ngắt / không phản hồi

1. Decision lưu mã truy vết khi nhận reading
2. Không có kết quả Analysis trong **5 giây** (cấu hình được)
3. → Áp **ngưỡng cứng** (nhiệt độ $\geq 40^{\circ}\text{C}$, $\text{PM}_{2.5} \geq 75$, $\text{CO}_2 \geq 1500$)
4. → Phát cảnh báo **degraded** (mức độ suy giảm)
5. Sensor & Decision **tiếp tục chạy** — hệ **không sập toàn bộ**

Kết quả analysis đến muộn (sau fallback) bị **bỏ qua** — tránh cảnh báo trùng lặp

Công nghệ sử dụng

Thành phần	Công nghệ
Ngôn ngữ	Python 3.11
Broker	Eclipse Mosquitto 2
MQTT client	Paho MQTT
AI	scikit-learn → ONNX → ONNX Runtime
Đóng gói	Docker Compose (2 vCPU, 4 GB mỗi agent)
Quan sát	Flask + WebSocket + Chart.js (dashboard)
Đo lường	psutil, script thu thập metrics, docker stats

Cấu trúc dự án

Thư mục / module	Chức năng
agents/	Ba agent: sensor, analysis, decision
shared/	Schema message, cấu hình, model ONNX, metrics
broker/	Cấu hình MQTT broker
dashboard/	Giao diện web giám sát realtime
scripts/	Huấn luyện, kiểm thử, đo lường, mô phỏng lỗi
models/	Model ONNX phát hiện bất thường
reports/	Số liệu thực nghiệm & báo cáo

Quy ước: không import chéo agent, bản tin lỗi không làm crash, mọi message có mã truy vết

Triển khai & tái lập

Bước	Mô tả
1	Khởi động stack Docker (3 agent + broker + dashboard)
2	Kiểm tra pipeline bình thường (3 chu kỳ E2E)
3	Thu thập metrics trong cửa sổ 40 giây
4	Mô phỏng lỗi: dừng Analysis Agent
5	Xác nhận cảnh báo degraded, hệ vẫn hoạt động

- Dashboard truy cập tại **cổng 5001** (host)
- Mỗi agent giới hạn **2 vCPU / 4 GB** — mô phỏng VM edge

Thiết lập thí nghiệm

Tham số	Giá trị
Nền tảng	Docker Compose
Giới hạn agent	2 vCPU, 4 GB RAM, CPU-only
Cửa sổ đo	40 giây
Chu kỳ sensor	2 giây
Timeout Analysis	5 giây
Ngày đo	2026-07-27

Kết quả — tài nguyên (RAM)

Thành phần	CPU (mẫu)	RAM sử dụng	Giới hạn
sensor_agent	0,08%	20,89 MiB	4 GiB
analysis_agent	0,21%	51,54 MiB	4 GiB
decision_agent	0,19%	20,11 MiB	4 GiB
mqtt-broker	0,54%	2,74 MiB	—

→ Analysis cao nhất $\approx$ **1,26%** trên 4 GB — **dư địa rất lớn** cho model phức tạp hơn

Kết quả — độ trễ & throughput

Chỉ số	Giá trị
Readings / results / alerts (40s)	21 / 21 / 21
E2E latency p50	9,48 ms
E2E latency p95	49,72 ms
Inference ONNX p50 / p95	4,98 ms / 6,94 ms
Throughput	≈ 0,525 msg/s (khớp interval 2s)
Degraded (cửa sổ ổn định)	0

E2E p50 ~10 ms — phù hợp giám sát môi trường gần realtime trên CPU biên

Phân tích trade-off

Trục	Quan sát
Độ trễ ↔ tài nguyên	E2E p50 ~10 ms với RAM < 55 MiB/agent
Chất lượng ↔ model	Isolation Forest đủ demo synthetic; chưa phản ánh nhiều cảm biến thực
Độ bền ↔ độ trễ lỗi	Timeout 5s giữ hệ sống; E2E degraded ~5s
Framework	Vòng MQTT tự viết — tránh overhead CrewAI/LangGraph

Kịch bản lỗi (fault injection)

Quan sát	Kết quả
Dừng Analysis Agent	Decision phát cảnh báo degraded sau ~5s
E2E khi degraded	~5010–5155 ms (chỉ phối bởi timeout)
Sensor Agent	Tiếp tục gửi dữ liệu
Decision Agent	Fallback ngưỡng, không crash
Phục hồi	Khởi động lại Analysis Agent

→ Chứng minh **fault tolerance** — yêu cầu bắt buộc của đề tài

Dashboard giám sát realtime

Widget	Nội dung
Agent cards	Trạng thái alive / degraded / down + heartbeat
Sensor readings	4 thông số cập nhật mỗi lần publish
E2E Latency chart	Biểu đồ 60 điểm, thống kê p50 / p95 / last
ONNX Inference chart	Thời gian suy luận theo thời gian
Alert feed	30 cảnh báo gần nhất, màu theo mức độ

Dữ liệu MQTT → WebSocket → trình duyệt (Flask-SocketIO + Chart.js)

Kịch bản demo (5–10 phút)

1. Kiểm tra 4 container đang chạy, nêu giới hạn 2c/4GB
2. Xem mức sử dụng RAM — thấp hơn nhiều so với trần 4 GB
3. Theo dõi log pipeline theo mã truy vết
4. Chạy kiểm thử E2E bình thường
5. Mô phỏng lỗi: tắt Analysis Agent
6. Xác nhận cảnh báo degraded, sensor/decision vẫn sống
7. Phục hồi Analysis + mở dashboard

Đóng góp chính

1. Hệ multi-agent biên **tái lập được**, tuân thủ ngân sách 2c/4GB & MQTT thật
2. Pipeline AI ONNX gọn (~1,16 MB), inference **~5 ms** trên CPU
3. Cơ chế **degraded mode** demo được — hệ không sập khi 1 agent lỗi
4. Bộ số liệu E2E/inference/RAM + dashboard + công cụ mô phỏng lỗi

Hạn chế & hướng phát triển

Hạn chế hiện tại:

- Cảm biến giả lập, chưa triển khai phần cứng thật
- Chưa so sánh LLM nhỏ (Qwen2.5-0.5B Q4) vs ONNX
- Chưa đo năng lượng tiêu thụ / hybrid edge–cloud

Hướng mở rộng:

- Tích hợp cảm biến IoT thực (Modbus, Zigbee)
- Thử nghiệm LLM Q4 trên Analysis Agent ($\leq 1,5B$)
- Điều phối phi tập trung / replica Decision
- Triển khai lên 3 VM edge thật thay Docker Compose

Kết luận

Hệ **multi-agent trên edge** cho giám sát môi trường đã được triển khai đầy đủ:

- 3 agent độc lập, giao tiếp **MQTT**, AI cục bộ **ONNX**
- E2E **p50 $\approx 9,5$ ms**, RAM Analysis **≈ 52 MiB** — trong ngân sách 4 GB
- **Fault tolerance** qua chế độ degraded khi Analysis timeout
- Sẵn sàng demo, đo lường và mở rộng

Cảm ơn!

Q & A

Mã nguồn & báo cáo đề án — `repository edge-ai-multi-agent`